

Bioinformática

Clustering

Rodrigo Santamaría

- **Dándole al vino**
- Clustering
- Clústering jerárquico
- Anotaciones

Dándole al vino

Dándole al vino

Saccharomyces cerevisiae

La expresión genética

El cambio diáuxico

Dándole al vino

- Hay evidencias de la elaboración de vino por humanos desde hace 6000 años*
- Pero ojo, una **musaraña** le da al vino desde hace *millones* de años
 - En particular, al “vino de palma” **
 - Han desarrollado un metabolismo del alcohol que evita que se emborrachen***



musaraña
arborícola de cola
emplumada


*En 2011 se descubrieron en una cueva de Armenia una prensa de vino, vasijas de fermentación y copas

**Producido por una flor que fermenta naturalmente gracias a la levadura *Saccharomyces cerevisiae*

***Cualquier mamífero que tomara las dosis de alcohol que toma, proporcionalmente, esta musaraña, moriría


Saccharomyces cerevisiae

- Esta levadura* fermenta el vino:
 - Se encuentra en los viñedos de forma natural
 - Se alimenta de la **glucosa** de la fruta
 - Produce **etanol**
- **Cambio diaúxico:** si se queda sin glucosa, puede, en presencia de **oxígeno**, alimentarse del etanol
 - Convirtiendo el vino en vinagre
 - Por eso las barricas de vino han de sellarse



*Las levaduras forman parte del reino animal de los *hongos*, son organismos *eucariotas unicelulares*. Son muy interesantes como organismos modelo al ser fáciles de cultivar y tener una estructura celular similar a la nuestra

Expresión génica



expresión

La descripción de este flujo de información biológica (simplificado aquí) se conoce como el *dogma central de la biología molecular* (Crick, 1958)

El cambio diaúxico

- Este cambio afecta a la expresión de muchos genes
- Es una ventaja evolutiva muy grande
 - La levadura puede **matar a sus competidores** generando etanol (tóxico para muchas bacterias)
 - Puede utilizar ese ***etanol como fuente de energía***
 - En ausencia de O₂ la levadura **hiberna**

Matrices de expresión

- Una matriz E de dimensión $n \times m$
 - n **genes** (típicamente todos los del genoma)
 - m **condiciones** experimentales
 - Distintos puntos temporales
 - Distintas condiciones ambientales, tejidos, etc.
 - E_{ij} expresión del gen i bajo la condición j
- Permiten realizar muchos **análisis**
 - Detectar genes que cambian su expresión
 - Detectar genes que varían de manera similar, etc.

Expresión del cambio diaúxico

- Joseph DeRisi (1997)* hizo el primer experimento de expresión genómica de cambio diaúxico
 - Matriz 6400 x 7
 - Todos los genes del genoma de *S cerevisiae*
 - 7 puntos temporales: -6,-4,-2,0,2,4,6
 - 0 es el punto donde se produce el cambio diaúxico




*El paper completo aquí: <http://vis.usal.es/rodrigo/documentos/bioinfo/papers/DeRisi1997.pdf>

Expresión del cambio diaúxico

diauxic shift

	-6	-4	-2	0	2	4	6
YLR258W	1.07	1.35	1.37	3.70	4.00	10.00	5.88
YPL012W	1.06	0.83	0.90	0.44	0.33	0.13	0.12
YPR055W	1.11	1.11	1.12	1.06	1.05	1.06	1.05

Expresión del gen YPR055W 2h después del cambio



La expresión en *log2* hace que los valores menores que uno sean negativos y proporcionales a los positivos:

- 1 se duplica
- -1 se divide entre 2

¿Cuál de estos tres genes crees que estaría involucrado en el cambio diaúxico?

Fold change

	diauxic shift						
	-6	-4	-2	0	2	4	6
YLR258W	1.07	1.35	1.37	3.70	4.00	10.00	5.88
YPL012W	1.06	0.83	0.90	0.44	0.33	0.13	0.12
YPR055W	1.11	1.11	1.12	1.06	1.05	1.06	1.05

Estos valores están expresados en ***fold change***

fold change ~ variación respecto a la referencia (doble, triple, mitad, etc.)

$$fc(-6h) = \text{expr}(-6h) / \text{expr}(\text{ref})$$

A menudo se transforman a **log2** fold change
hace simétrica la variación
evita que se disparen los valores muy altos

A	B	fc	logfc
1	2	2.00	1
100	200	2.00	1
200	100	0.50	-1
100	400	4.00	2
400	100	0.25	-2
0	100	Inf	Inf

Ejercicio

- 1) Descarga el experimento de DeRisi aquí:
 - <http://vis.usal.es/rodrigo/documentos/bioinfo/expresion/2010diauxic-edited.txt>
 - El experimento ya se encuentra en log2 fc
 - ¿Podrías encontrar esta matriz en la red? ¿Dónde?
- 2) Carga la matriz m anterior con python
 - `numpy.genfromtxt*` o `csv.reader`
 - ¿Qué dimensiones tiene?**
- 3) Selecciona los genes con expresión (log2) en valor absoluto >2.3 para alguno de los tiempos
 - Utiliza para ello `numpy.any` y `numpy.where`
 - Los llamaremos dgenes y a su matriz de expresión dm.
¿Cuántos genes son?

*Necesitarás hacer uso de los argumentos `delimiter`, `names`, `dtype`, `skip_header` y/o `usecols`

IMPORTANTE: También necesitarás usar `filling_values=0` para los valores perdidos

**Pista: `shape`

- Dándole al vino
- **Clustering**
- Clustering jerárquico
- Anotaciones

Clustering

Cluster y clustering

Error cuadrático medio

Algoritmo de Lloyd





Jaboticaba, árbol de la uva (Brasil)

Cluster

- **Conjunto** de elementos con un **patrón similar**
 - Y **distinto** al del resto de elementos
 - En nuestro caso, conjuntos de genes con niveles de activación similares a lo largo del tiempo
 - La mayoría de genes tendrán seguramente un patrón **plano**, al no estar involucrados en el cambio diaúxico
 - Si eliminamos todos los genes que tienen todos los valores (log2) de su perfil entre -2.3 y 2.3, nos quedamos con sólo 229 de 6400 genes

¿por qué 2.3 como umbral?

Clustering

- Algoritmo para encontrar clusters
 - Caracterizarlos mediante **centroides**
 - puntos en el “medio” de cada cluster
 - **Optimizar** la **distancia** de los centroides a los puntos que agrupa
 - Típicamente, se usa la distancia **euclídea***
 - Sean dos puntos m-dimensionales $a=(a_1,...,a_m)$ y $b=(b_1,...,b_m)$:

$$d(a, b) = \sqrt{\sum_{i=1}^m (a_i - b_i)^2}$$

- Definimos la distancia a un conjunto de centroides como:

$$d(\text{punto}, \text{Centroides}) = \min_{\forall x \in \text{Centroides}} d(\text{punto}, x)$$

*En python podemos calcularla con `numpy.linalg.norm(a-b)`

Más lejano primero

- Estrategia de optimización:
 1. Tomar un punto cualquiera como centroide
 2. Añadir nuevos centroides eligiendo de entre los puntos restantes aquél más lejano a todos los centroides actuales hasta que $|\text{centroides}| = k$

MasLejanoPrimero(Puntos, k)

Centroides <- un punto aleatorio de *Puntos*

mientras $|\text{Centroides}| < k$

punto <- punto en *Puntos* que maximice $d(\text{punto}, \text{Centroides})$





 añadir *punto* a *Centroides*

retornar *Centroides*


Ejercicio 1

- Implementar la función `farthestFirst`:
 - **entrada:**
 - E matriz de puntos $n \times m$
 - k número de clusters
 - init punto inicial (en vez de aleatoriamente, se lo suministramos)
 - **salida:** centroides según este algoritmo
- Ejemplo:
 - E: `np.array([[3,20],[4,22],[5,23],[3,18],[4,21],[5,24],[21,10],[22,12],[23,13],[21,8],[20,11],[24,13],[11,2],[12,1],[13,3],[15,4],[11,3],[14,2]])`
 - k: 3
 - init: `[3,20]`
 - salida: `[[3,20], [24,13], [11,2]]`
- Prueba:
 - E=dm (la matriz de expresión de dgenes)
 - k=3
 - init=`[-0.23, -0.09, -0.27, 0.2, 0.56, 1.52, 2.64]`

farthestFirst



farthestFirst



- Este algoritmo es muy rápido y puede dar buenos resultados.
- Pero tiene problemas para tratar con *outliers* (casos atípicos), muy comunes en bioinformática

Error cuadrático medio (MSE*)

- Media de todas las distancias a centroides
 - Más moderado que tomar sólo la máxima

$$MSE = \frac{1}{n} \sum_{\forall \text{ punto en Puntos}} d(\text{punto}, \text{Centroides})^2$$

Ejercicio 2

- Implementar la función mse:

- **entrada:**

- points array de puntos n-dimensionales
 - centers array de centroides n-dimensionales

- **salida:** error cuadrático medio

- Ejemplo:

- points: array([[1, 24], [4, 2], [23, 20], [24, 22], [25, 23], [23, 18], [24, 21], [25, 24], [31, 10], [32, 12], [33, 13], [31, 8], [30, 11], [34, 13], [21, 2], [22, 1], [23, 3], [25, 4], [21, 3], [24, 2]])
 - centers: array([[1, 24], [31, 8], [4, 2]])
 - salida: 104.95

- Prueba:

- points= array([[3, 20], [4, 22], [5, 23], [3, 18], [4, 21], [5, 24], [21, 10], [22, 12], [23, 13], [21, 8], [20, 11], [24, 13], [11, 2], [12, 1], [13, 3], [15, 4], [11, 3], [14, 2]])
 - centers=[[3, 20], [24, 13], [14, 2]]

Algoritmo de Lloyd

- **Centroide:** punto cuyas coordenadas son la media de las coordenadas de un conjunto de puntos

Lloyd(Puntos, k)

Centroides <- k puntos aleatorios en *Puntos*

Clusters = []

hacer

Clusters <- asignar cada *punto* en *Puntos* al centroide más cercano





Centroides <- recalcular los centroides de cada cluster en *Clusters*

hasta convergencia*


retornar *Clusters*

* Entendida como que los centroides no cambien o cambien menos que un determinado valor respecto a la iteración anterior

Algoritmo de Lloyd



Algoritmo de Lloyd




En la it. 2 no hay cambio de cluster para ningún punto, así que los nuevos centroides son iguales que en la iteración anterior, y el algoritmo termina

*¿El algoritmo de Lloyd converge en cualquier caso?
¿Cuántas iteraciones tardaría como máximo?
¿Siempre da la misma agrupación?
¿Asegura la mejor agrupación posible?*

Algoritmo de Lloyd

- La inicialización aleatoria puede dar lugar a problemas a la hora de detectar clusters



inicializacionKmedias(Puntos, k)

Centroides <- un punto aleatorio en *Puntos*

mientras |*Centroides*|<k

puntoNuevo <- elegir aleatoriamente un punto de *Puntos* pero con probabilidades asignadas proporcionales a $d(\text{punto}, \text{Centroides})^2$


añadir *puntoNuevo* a *Centroides*

retornar *Centroides*

Ejercicio 3

- Implementar la función `lloyd` (con la inicialización de k-medias)*:
 - **entrada:**
 - `points` array de puntos n-dimensionales
 - `k` número de clusters
 - `convergence` distancia media máxima entre los centroides de dos iteraciones considerada para terminar el algoritmo
 - `iterations` número máximo de iteraciones en caso de que no se llegue a convergencia
 - **salida:** array con el número de cluster al que pertenece cada punto
- Ejemplo:
 - Points: `array([[3, 20], [4, 22], [5, 23], [3, 18], [4, 21], [5, 24], [21, 10], [22, 12], [23, 13], [21, 8], [20, 11], [24, 13], [11, 2], [12, 1], [13, 3], [15, 4], [11, 3], [14, 2]])`
 - `k`: 3
 - `convergence`: 0.1
 - `iterations`: 100
 - Salida... hay una única solución?
- Prueba:
 - Añadir un tercer parámetro opcional `initCenters` que indique un array de puntos iniciales a usar en vez de tomarlos aleatoriamente de `points`
 - Utilizar los mismos parámetros del ejemplo más:
 - `initCenters=array([[3,20], [24,13], [14,2]])`

Clusters en el cambio diaúxico



- Aplicando el algoritmo de Lloyd con $k=6$ a dm , obtenemos 6 clusters de patrones distintos respecto al cambio diaúxico
- Estos patrones generan nuevas preguntas biológicas: ¿Por qué aumentan su expresión los genes en el cluster 1, 3 y 6? ¿por qué disminuyen en los clusters 2, 4 o 5? ¿En qué medida esos cambios contribuyen al cambio diaúxico?

Clustering de k-medias: problemas

- El algoritmo de Lloyd es muy similar a otras aproximaciones como el clustering de k-medias, y presenta problemas similares:
 - Problemas de clasificación
 - Imposición de k a priori
 - No indica las similitudes entre clusters
 - No determinista (aleatorización en el inicio)

- Dándole al vino
- Clustering
- **Clustering jerárquico**
- Anotaciones

Clustering jerárquico

Matriz de distancias

Clustering jerárquico

Interpretación de resultados

Matriz de distancias

- Sea una matriz de expresión E $n \times m$
 - La matriz de distancias D es una matriz $n \times n$ donde $D_{ij}=d(g_i, g_j)$
 - Siendo d la distancia Euclídea (normalmente)
 - Siendo g_i y g_j los perfiles de expresión de los genes correspondientes a las filas i y j de E
- En python la podemos calcular con:
`distm=scipy.spatial.distance.pdist(e)`
`distms=scipy.spatial.distance.squareform(distm)*`

*`pdist` calcula la matriz de distancias en forma condensada (ya que es una matriz triangular de diagonal cero).
`squareform` permite recuperar la matriz redundante cuadrada correspondiente.

Matriz de distancias

	1 hr	2 hr	3 hr
G₁	10.0	8.0	10
G₂	10.0	0.0	9.0
G₃	4.0	8.5	3.0
G₄	9.5	0.5	8.5
G₅	4.5	8.5	2.5
G₆	10.5	9.0	12.0
G₇	5.0	8.5	11.0
G₈	3.7	8.7	2.0
G₉	9.7	2.0	9.0
G₁₀	10.2	1.0	9.2


Matriz *E* (izquierda) y matriz *D* (abajo)
D se ha realizado con distancias
 euclídeas, y es una matriz triangular y
 de diagonal cero.

	g₂	g₃	g₄	g₅	g₆	g₇	g₈	g₉	g₁₀
g₁	8.1								
g₂		12.0							
g₃			11.2						
g₄				11.2					
g₅					11.2				
g₆						5.6			
g₇							9.1		
g₈								11.4	
g₉									1.1


Clustering jerárquico

- Este método agrupa los elementos más cercanos iterativamente
- Una forma común es agrupar por pares según una distancia media entre grupos
 - UPGMA (**U**nweighted **P**aired **G**roup **M**ethod with **A**rithmetic mean)


	g_2	g_3	g_4	g_5	g_6	g_7	g_8	g_9	g_{10}
g_1	8.1	9.2	7.7	9.3	2.3	5.1	10.2	6.1	7.0
g_2		12.0	0.9	12.0	9.5	10.1	12.8	2.0	1.0
g_3			11.2	0.7	11.1	8.1	1.1	10.5	11.5
g_4				11.2	9.2	9.5	12.0	1.6	1.1
g_5					11.2	8.5	1.0	10.6	11.6
g_6						5.6	12.1	7.7	8.5
g_7							9.1	8.3	9.3
g_8								11.4	12.4
g_9									1.1



	g_2	$g_{3,5}$	g_4	g_6	g_7	g_8	g_9	g_{10}
g_1	8.1	9.2	7.7	2.3	5.1	10.2	6.1	7.0
g_2		12.0	0.9	9.5	10.1	12.8	2.0	1.0
$g_{3,5}$			11.2	11.1	8.1	1.0	10.5	11.5
g_4				9.2	9.5	12.0	1.6	1.1
g_6					5.6	12.1	7.7	8.5
g_7						9.1	8.3	9.3
g_8							11.4	12.4
g_9								1.1



	$g_{2,4}$	$g_{3,5}$	g_6	g_7	g_8	g_9	g_{10}
g_1	7.7	9.2	2.3	5.1	10.2	6.1	7.0
$g_{2,4}$		11.2	9.2	9.5	12.0	1.6	1.0
$g_{3,5}$			11.1	8.1	1.0	10.5	11.5
g_6				5.6	12.1	7.7	8.5
g_7					9.1	8.3	9.3
g_8						11.4	12.4
g_9							1.1



Clustering jerárquico

clusteringJerarquico(D , k)

$Clusters \leftarrow n$ clusters de un elemento etiquetados de 1 a n
construir un grafo T con n nodos aislados etiquetados de 1 a n
 $cont \leftarrow n$

mientras $|Clusters| > k$

$C_{cont} \leftarrow$ fusión de los $Clusters$ más cercanos C_i y C_j

añadir un nodo C_{cont} a T

conectar C_{cont} a los nodos C_i y C_j

eliminar de D las filas y columnas correspondientes a C_i y C_j

añadir una fila/columna a D con $D(C_{cont}, C)$ para todo C en $Clusters$

eliminar C_i y C_j de $Clusters$

añadir C_{cont} a $Clusters$

$cont \leftarrow cont + 1$

$raiz \leftarrow$ nodo en T correspondiente al cluster final

retornar $|Clusters|$

Clustering jerárquico

- La distancia $D(C_1, C_2)$ entre clusters se puede definir de distintos modos.
- En UPGMA se usa la distancia media entre los elementos de los dos clusters:


$$D_{avg}(C_1, C_2) = \frac{\sum_{\forall \text{ punto } i \text{ en } C_1 \text{ y } j \text{ en } C_2} d_{i,j}}{|C_1| \cdot |C_2|}$$

Ejercicio 4

- Implementar la función `hierarchicalClustering`
 - **entrada:**
 - E matriz o array de puntos n-dimensionales
 - k número de clusters en el que se divide el árbol
 - **salida:** diccionario con los clusters formados. Las claves indicarán el nodo del árbol que se usa para el cluster y los valores la lista de nodos hoja (filas de E) que contiene el cluster.
- Ejemplo:
 - E: `array([[ 10., 8., 10.], [10., 0., 9. ], [4. , 8.5, 3. ], [9.5, 0.5, 8.5], [4.5, 8.5, 2.5], [10.5, 9., 12. ], [5., 8.5, 11.], [3.7, 8.7, 2. ], [9.7, 2. , 9. ], [10.2, 1., 9.2]])`
 - Se corresponde con la matriz 10x3 de la diap. 30
 - k: 3
 - Resultado intermedio (árbol hasta la raíz): `{0:[], 1:[], 2:[], 3:[], 4:[], 5:[], 6:[], 7:[], 8:[], 9:[], 10:[2, 4], 11:[1, 3], 12:[7, 10], 13:[9, 11], 14:[8, 13], 15:[0, 5], 16:[6, 15], 17:[14, 16], 18:[12, 17]}`
 - Salida: `{12: [7, 2, 4], 14: [8, 9, 1, 3], 16: [6, 0, 5]}`
- Prueba:
 - E: dm
 - k: 6

Ejercicio 4 (estructura de datos)

	g_2	g_3	g_4	g_5	g_6	g_7	g_8	g_9	g_{10}
g_1	8.1	9.2	7.7	9.3	2.3	5.1	10.2	6.1	7.0
g_2		12.0	0.9	12.0	9.5	10.1	12.8	2.0	1.0
g_3			11.2	0.7	11.1	8.1	1.1	10.5	11.5
g_4				11.2	9.2	9.5	12.0	1.6	1.1
g_5					11.2	8.5	1.0	10.6	11.6
g_6						5.6	12.1	7.7	8.5
g_7							9.1	8.3	9.3
g_8								11.4	12.4
g_9									1.1



g_1 a g_{10} (nodos hoja)

$g_{3,5}$

{1:[], 2:[], 3:[], 4:[], 5:[], 6:[], 7:[], 8:[], 9:[], 10:[], 11: [2, 4]}

- Almacenaremos el árbol como un diccionario.
- Cada clave indica 1) un nodo intermedio del árbol cuyo valor es un array con sus dos nodos hijos, o 2) un nodo hoja (i.e una fila de la matriz inicial) cuyo valor es un array vacío
- Los nodos hoja deben identificarse con claves $i=0$ a $N-1$, donde i corresponde a la fila de la matriz de expresión E en la que se encuentra el punto.
- Los nodos intermedios deben identificarse con claves $i=N, N+1, \dots$ por orden de distancia, siendo N el que indica la bifurcación de los dos puntos de E con menor distancia.

Clusters en el cambio diaúxico



- Cortando por 6 clusters, obtenemos clusters de tamaños 1, 6, 102, 34, 10 y 76, respectivamente
- Los resultados son distintos a los obtenidos con el clustering de k-medias, ya que hay varias diferencias procedimentales (cálculo de distancias, modo de agrupamiento, etc.)

Clustering e interpretación biológica

- El clustering es sólo un **primer paso** en el análisis de un experimento
- Le siguen **más experimentos** para confirmar que los clusters tienen **sentido biológico**
- Hay también pruebas bioinformáticas para identificar si
 - Hay **motivos en las secuencias** encontradas
 - P. ej. el motivo regulador CSRE se encuentra en varios genes con activación diaúxica [Schöler y Schüller, 1994]
 - Como vimos en la sesión 3 (muestreo de Gibbs, p. ej.)
 - Hay **funciones biológicas** conocidas relacionadas con los grupos

- Dándole al vino
- Clustering
- Clustering jerárquico
- **Anotaciones**

Anotaciones

Anotaciones genéticas


Anotaciones funcionales

Enriquecimiento funcional

Anotaciones de un gen

- Características generales (GFF)
 - Nombre y sinónimos
 - Estructura
 - Posición
 - Locus
 - Posición (comienzo y fin) en el cromosoma
 - Cromosoma en el que se encuentra
 - Sentido o antisentido
- Secuencia (FASTA)
- Funciones conocidas (OBO, otros)

Estructura de un gen



https://en.wikipedia.org/wiki/File:Gene_structure_eukaryote_2_annotated.svg

Estructura de un gen

- **Open Reading Frame (ORF):** región abierta para transcripción por parte de la DNA polimerasa
- **Start/Stop:** codones o secuencias de inicio/parada de la transcripción
- **Untranslated Regions (UTR):** regiones en los extremos 5' o 3' que ayudan al inicio/fin de la transcripción *y que se incluyen* en el mRNA
- **Secuencia regulatoria:** secuencia previa/posterior a un ORF que *modula* su transcripción
 - Promotor: acumula las proteínas necesarias para la transcripción
 - Catalizador/Silenciador: mejora/obstaculiza la transcripción
- **Exon:** sección del ORF en el mRNA que terminará formando la proteína
- **Intron:** sección del ORF en el mRNA que *no* forma la proteína
- **Secuencia de DNA codificante (CDS):** DNA que forma parte de la proteína. Equivale a los exones sin los UTR

General Feature Format (GFF)

Position index	Position name	Description
1	sequence	The name of the sequence where the feature is located.
2	source	Keyword identifying the source of the feature, like a program (e.g. Augustus or RepeatMasker) or an organization (like TAIR).
3	feature	The feature type name, like "gene" or "exon". In a well structured GFF file, all the children features always follow their parents in a single block (so all exons of a transcript are put after their parent "transcript" feature line and before any other parent transcript line). In GFF3, all features and their relationships should be compatible with the standards released by the Sequence Ontology Project .
4	start	Genomic start of the feature, with a 1-base offset . This is in contrast with other 0-offset sequence formats, like BED files .
5	end	Genomic end of the feature, with a 1-base offset . This is in contrast with other 0-offset sequence formats, like BED files .
6	score	Numeric value that generally indicates the confidence of the source on the annotated feature. A value of "." (a dot) is used to define a null value.
7	strand	Single character that indicates the Sense (molecular biology) strand of the feature; it can assume the values of "+" (positive, or 5'→3'), "-", (negative, or 3'→5'), "." (undetermined).
8	frame (GTF, GFF2) <i>or</i> phase (GFF3)	Frame or phase of CDS features; it can be either one of 0, 1, 2 (for CDS features) or "." (for everything else). See following subsection.
9	Attributes.	All the other information pertaining to this feature. The format, structure and content of this field is the one which varies the most between the three competing file formats.

Identificador

Tipo de estructura

Posición

Sentido

Otra información

https://en.wikipedia.org/wiki/General_feature_format

General Feature Format

Los comentarios comienzan por #

Es común que los campos no se utilicen correctamente, aquí el campo 1 (ID) se usa para indicar el cromosoma

El campo 2 nos indica la fuente de la información, en este caso SGD (Saccharomyces Genome Database)

Los campos vacíos se identifican con . aunque no siempre!

El campo 9 se suele sobrecargar de información no estandarizada

```
##gff-version 3
#date Thu Jun 30 19:50:03 2016
...
chrV    SGD gene    285241 286914 .    -    .
ID=YER065C;Name=YER065C;gene=ICL1;Alias=ICL1,isocitrate
lyase1;Ontology_term=G0:0004451,G0:0005737,G0:0006097;Note=Isoci
trate lyase B catalyzes the formation of succinate and
glyoxylate from isocitrate-C a key reaction of the glyoxylate
cycle B expression of ICL1 is induced by growth on ethanol and
repressed by growth on glucose;display=Isocitrate
lyase;dbxref=SGD:S0000000867;orf_classification=Verified
chrV    SGD CDS    285241 286914 .    -    0
Parent=YER065C_mRNA;Name=YER065C_CDS;orf_classification=Verified
chrV    SGD mRNA    285241 286914 .    -    .
ID=YER065C_mRNA;Name=YER065C_mRNA;Parent=YER065C
...
```

Cada entrada está delimitada por tabuladores

Ejercicio 5

- Implementar la función `annotations`
 - **Entrada:**
 - `ids`: array con nombres de genes en según el experimento de DeRisi
 - **Salida:** diccionario con los nombres de los genes como claves y como valores un diccionario con los campos `start`, `end`, `gene` e `id`
 - `id` es el número entre SGD= y ; en la columna 9
 - `gene` se encuentra también como subcampo en la columna 9.
 - Si no está o está vacío, se usará el valor en `Name=`
 - Utilizad la versión de SGD R64-2-1 (30 de enero de 2016)*
 - ¿Podrías obtener una versión más actualizada?
- Ejemplo
 - `[YER065C]`
 - `{'YER065C': {'end': '286914', 'id': 'S0000000867', 'name': 'ICL1', 'start': '285241'}}`
- Prueba: `['YPR184W', 'YLR312C', 'YML054C', 'YBR116C', 'YKL187C', 'YLR267W', 'YEL012W', 'YOL084W', 'YJL045W', 'YJR095W']`

Anotaciones funcionales: ontologías

- **Ontología:** vocabulario controlado
 - Jerarquizado en forma de grafo dirigido acíclico (DAG)
 - Se puede ver como un 'árbol complejo'
- **Gene Ontology (GO):** ontologías biológicas*
 - Componentes Celulares (**CC**)
 - Funciones moleculares (**MF**)
 - Procesos Biológicos (**BP**)
 - Es la ontología más extendida, pero no la única
 - KEGG (rutas biológicas), Reactome (reacciones químicas), etc.

Open Biomedical Ontologies (OBO)

- Estándar para representar ontologías*
- Cada término del vocabulario se representa con un párrafo:


```
[Term]
id: GO:0000001
name: mitochondrion inheritance
namespace: biological_process
def: "The distribution of mitochondria, including the
mitochondrial genome, into daughter cells after mitosis or
meiosis, mediated by interactions between mitochondria and
the cytoskeleton." [GOC:mcc, PMID:10873824, PMID:11389764]
synonym: "mitochondrial inheritance" EXACT []
is_a: GO:0048308 ! organelle inheritance
is_a: GO:0048311 ! mitochondrion distribution
```

Gene Ontology Annotations (GOA)

- En un organismo, cada gen está *anotado con* términos de la ontología
- **Gene Association File (GAF)**
 - Formato común para representar las anotaciones
 - Formato tabulado de 17 campos
 - Los comentarios empiezan por “!”

Column	Content	Required?	Cardinality	Example
1	DB	required	1	UniProtKB
2	DB Object ID	required	1	P12345
3	DB Object Symbol	required	1	PHO3
4	Qualifier	optional	0 or greater	NOT
5	GO ID	required	1	GO:0003993
6	DB:Reference (DB:Reference)	required	1 or greater	PMID:2676709
7	Evidence Code	required	1	IMP
8	With (or) From	optional	0 or greater	GO:0000346
9	Aspect	required	1	F
10	DB Object Name	optional	0 or 1	Toll-like receptor 4
11	DB Object Synonym (Synonym)	optional	0 or greater	hToll Tollbooth
12	DB Object Type	required	1	protein
13	Taxon(taxon)	required	1 or 2	taxon:9606
14	Date	required	1	20090118
15	Assigned By	required	1	SGD
16	Annotation Extension	optional	0 or greater	part_of(CL:0000576)
17	Gene Product Form ID	optional	0 or 1	UniProtKB:P12345-2

Gene Annotation File (GAF)



* Muy importante para el biólogo, pues hay evidencias más contundentes que otras. En general, suele ser recomendable tratar con precaución aquellas inferidas electrónicamente (IEA).

Para consultar todos los códigos: <http://www.geneontology.org/page/guide-go-evidence-codes>

Ejercicio 6

- Implementar la función `functions`
 - **Entrada:**
 - `ids`: array con nombres de genes según el experimento de DeRisi
 - **Salida:** diccionario con los ids de genes como claves y como valores un conjunto (set) con los *nombres* de los procesos biológicos (P) con los que está anotado que no estén inferidos electrónicamente (IEA)
 - NOTA: si algún gen no tienen ninguna anotación, igualmente debe tener una clave y un valor asociado que sea un conjunto vacío
 - Utilizad las versiones:
 - GO: la versión del SGD R64-2-1, de 11 de febrero de 2016*
 - GAF: versión 34023 de 25 de junio de 2016**
 - ¿Podrías obtener una versión más actualizada? ¿Dónde?
- Ejemplo
 - [YER065C]
 - {'S0000000867': set(['glyoxylate cycle'])}
- Prueba: ['YPR184W', 'YLR312C', 'YML054C', 'YBR116C', 'YKL187C', 'YLR267W', 'YEL012W', 'YOL084W', 'YJL045W', 'YJR095W']

* <http://vis.usal.es/rodrigo/documentos/bioinfo/anotaciones/scerevisiae/go.obo>


** http://vis.usal.es/rodrigo/documentos/bioinfo/anotaciones/scerevisiae/gene_association.sgd

Anotaciones: problemas

- A pesar de los esfuerzos de estandarización
 - Existen muchos nombres e identificadores distintos para cada gen
 - Los formatos cambian ligeramente entre organismos
 - Hay errores en el uso de los formatos
- El parseo de este tipo de archivos suele consumir mucho tiempo de programación

Enriquecimiento estadístico

- Sean dos conjuntos G y F de elementos g_i y f_i tomados de un universo de elementos U
 - F está *enriquecido* por G si contiene un número de los elementos de G que no puede deberse al azar, teniendo en cuenta los tamaños de G , F y U



¿Cuál de estos conjuntos G crees que enriquece más a F ?

Test de Fisher

- Sean dos grupos X e Y con elementos que cumplen o no una determinada condición F
- Sea su **matriz de contingencia**:

	X	Y	Total
Cumplen F	a	b	$a+b$
No cumplen F	c	d	$c+d$
Total	$a+c$	$b+d$	$a+b+d+c=n$

- Fisher demostró que la probabilidad p de esta matriz es

$$p = \frac{(a+b)! (c+d)! (a+c)! (b+d)!}{a! b! c! d! n!}$$

Test de Fisher: ejemplo

- Consideremos un grupo G de genes, y otro grupo con el resto de genes de nuestro universo ($U-G$).
- Respecto a una anotación F , la matriz de contingencia es:

	G	$U-G$	Total
En F	10	30	40 = $ F $
No en F	20	140	160
Total	30 = $ G $	170	200 = $ U $

1. Tenemos 40 de un total de 200 genes anotados con la función F
2. El grupo G tiene 10 de sus 30 genes anotados con la función F
3. Asumimos la hipótesis nula H_0 de que tanto los genes en G como el resto ($U-G$) tienen la misma probabilidad de estar en F
4. ¿Si hubiéramos cogido $|G|$ genes al azar, cual es la probabilidad de tener esta tabla de contingencia o una con incluso más genes de G en F ?:

$$p = \frac{40!160!30!170!}{10!30!20!140!200!} = 0.046325$$






Ejercicio 7


- Implementar la función `enrichment`
 - **Entrada:**
 - `ids`: conjunto con genes de interés
 - `goids`: conjunto con genes anotados con una función
 - `n`: número total de genes en el universo
 - **Salida:** p-valor del test de Fisher para esta comparación*
 - Utilizad las versiones de GO y GAF que se indican en el ejercicio 5
- Ejemplo
 - `ids=set(range(30))`
 - `goids=set(range(20, 60))`
 - `n=200`
 - `salida: 0.046325`
- Prueba:
 - `ids=dgenes`, los genes relacionados con el cambio diaúxico**
 - `goids=genes` en el término *alcohol metabolic process* (GO:0006066):
 - `{'S0000000056', 'S0000000080', 'S0000000702', 'S0000000826', 'S0000004937'}`
 - `n=6034` (núm. de genes en la matriz de expresión de DeRisi)

*PISTA: si usas python, usa la función `fisher_exact`, de la librería `scipy.stats`, usando `alternative="greater"` y el campo `pvalue` del resultado. Investiga también el uso de `set` y sus operaciones para intersección, unión, diferencia, etc.

** <http://vis.usal.es/rodrigo/documentos/bioinfo/expresion/diau/dgenes.txt>

¿Cuál de estos conjuntos G crees que enriquece más a F ?





Test de Fisher: interpretación

- Si el p-valor es suficientemente bajo, podemos decir que no se debe al azar el hecho de que hayamos cogido varios elementos de F en G
 - Es decir, F se encuentra **enriquecido** en G
- ¿Qué es suficientemente bajo?
 - Se suele estimar un umbral $\alpha=0.05, 0.01$ o 0.001
 - Probabilidad $\leq 5\%$, 1% o 0.1% de que se deba al azar

Test de Fisher: interpretación

- Un test de enriquecimiento permite **rechazar o no H_0** (una determinada circunstancia no parece o sí parece debida al azar, respectivamente)
- Limitaciones de los tests de enriquecimiento [Khatri2005, Glass2014]:
 - No sirven para confirmar que los datos se deben al azar en caso de que no se rechace H_0
 - *No se puede confirmar totalmente el azar*
 - No permiten confirmar la hipótesis alternativa H_1
 - *No se puede confirmar totalmente la falta de azar*
 - Los umbrales son arbitrarios
 - Algunos genes están más anotados que otros, con lo que nuestra H_0 no es totalmente correcta

Contrastes múltiples de hipótesis

- Es normal realizar el test de enriquecimiento con **todos** los términos GO a la vez
 - Objetivo: detectar aquellos más enriquecidos
- Cuantos más tests realicemos, más posibilidades hay de que alguno de ellos caiga por azar por debajo del umbral fijado


Correcciones

- Corrección de **Bonferroni**
 - Se divide el umbral α entre el número de tests
 - $\alpha=0.05$, 10^6 tests $\rightarrow \alpha(\text{corregido})= 0.05/10^6 = 5 \cdot 10^{-8}$
- False Discovery Rate (**FDR**)*
 1. Se calculan los p-valores de nuestros N tests
 2. Se ordenan: $P_1 \leq P_2 \leq P_3 \dots \leq P_N$
 3. Para un valor α , se busca el valor más grande P_k tal que: $P_k \leq \frac{\alpha k}{N}$
 4. Se toma como FDR (umbral corregido) $Z=P_k$

Ejercicio 8

- Implementar la función `enrichmentAll`
 - **Entrada:**
 - `uids`: array con todos los nombres de genes en nuestro experimento
 - `gids`: array con todos los genes de interés (p.ej. los de un cluster)
 - `a`: umbral para determinar si hay enriquecimiento
 - `min`: mínimo número de anotaciones que debe tener un término para ser considerado
 - `max`: máximo número de anotaciones que debe tener un término para ser considerado
 - `type`: carácter 'P', 'C' o 'F' indicando el tipo de términos GO que se consideran
 - **Salida:** lista de diccionarios con los siguientes campos:
 - `name`: nombre del término GO enriquecido
 - `pval`: p-valor
 - `ngis`: número de genes en ids anotados con el término
 - `ngo`: número de genes en total anotados con el término
 - Utilizad las mismas versiones de GAF y GO que en el ejercicio 5
 - Como en el ej. 6, ignorad las anotaciones inferidas electrónicamente (IEA)

Ejercicio 8



- Ejemplo

- `gids=c3genes.txt*`

- `uids=ugenes.txt**`

- `a=10e-20, min=5, max=500, type='P'`

- Salida: `[{'name': 'cytoplasmic translation', 'ngis': 45, 'ngo': 170, 'pval': 8.43491843768445e-26}]`

- Compara este resultado con los resultados de DeRisi (en particular su fig. 5F)

- Prueba:

- `gids=randomGenes.txt***`

- `uids=ugenes.txt**`

- `n=número total de genes en DeRisi`

- `a=0.01, min=5, max=500, type='P'`

* Son los 102 genes del grupo 3 obtenido con el clustering jerárquico (diap. 35): <http://vis.usal.es/rodrigo/documentos/bioinfo/expresion/diau/c3genes.txt>

** Los 5945 genes de los que tenemos anotaciones en el GFF: <http://vis.usal.es/rodrigo/documentos/bioinfo/expresion/diau/ugenes.txt>

*** Un grupo de 102 genes elegidos aleatoriamente <http://vis.usal.es/rodrigo/documentos/bioinfo/expresion/diau/randomGenes.txt>

El peligro de los umbrales

- En la prueba del ej. 8 existen términos enriquecidos para randomGenes, incluso con $FDR=0.01$!
 - Es un umbral suficientemente bajo?
 - Hay 145 términos GO BP con entre 5 y 500 anotaciones que contengan alguno de los genes en randomGenes
 - $145 \times 0.01 = 1.45 \rightarrow$ hay posibilidades de que se nos cuele alguno
- Recomendaciones
 - Mejor pecar de falsos negativos que de falsos positivos
 - Usa umbrales $\ll 0.01$. De manera genérica, 10^{-6} puede estar bien teniendo en cuenta que tenemos unos 10^5 términos GO
 - O puedes afinar más usando cálculos como el anterior
 - Descarta términos con muy pocas o muchas anotaciones
 - Vigila siempre `ngis` y `ngo` además de `pval`

La trampa del informático

- Correlación **no implica causalidad**
 - No se puede saltar de una afirmación estadística a una explicación biológica
 - Necesidad de nuevos experimentos biológicos a la luz de los indicadores estadísticos

"The numbers are where the scientific discussion should start, not end."

Steven Goodman (ver [Nuzzo2014])

La trampa del biólogo

- La estadística **no se debe cocinar**
 - Los umbrales estadísticos deben ser rigurosos
 - No se pueden modificar los umbrales o modelos hasta que confirmen una teoría biológica


“P-hacking is trying multiple things until you get the desired result”

Uri Simonsohn [ver Nuzzo2014]

- **Muy importante:** estas dos “trampas” han poblado las bases de datos de falsos positivos y resultados no replicables

Bibliografía

- P. Compeau and P. Pevzner (**2015**). Bioinformatics Algorithms: An Active Learning Approach, 2nd ed. Vol II. Ch 8.
- Respeto al cambio diaúxico
 - DeRisi, J. L., Iyer, V. R., & Brown, P. O. (**1997**). Exploring the metabolic and genetic control of gene expression on a genomic scale. *Science*, 278(5338), 680-686.
 - <http://vis.usal.es/rodrigo/documentos/bioinfo/papers/DeRisi1997.pdf>
- Respecto a las limitaciones del p-valor
 - Nuzzo, R. (**2014**). Statistical errors. *Nature*, 506(7487), 150-152.
 - <https://www.nature.com/news/scientific-method-statistical-errors-1.14700>



Voronto, una herramienta para visualizar el enriquecimiento estadístico
<http://vis.usal.es/voronto>